

Passo a passo para a execução do MVP

Passo 1: Configuração do Ambiente

1. Instale as dependências necessárias:

- Linguagem de programação Python (versão ≥ 3.8).
- Biblioteca para interação com o Telegram: python-telegram-bot.
- Integração com Pinecone: pinecone-client.
- Modelos de linguagem (como OpenAI): openai ou similar.

● Outras dependências:

pip install langchain

pip install pydantic

pip install requests

2. Crie contas nas plataformas necessárias:

- **Telegram:** Configure um bot através do BotFather.
- **Pinecone:** Crie um índice em Pinecone para armazenar vetores.
- **OpenAI:** Gere uma chave de API para acessar os embeddings do GPT.

3. Configure variáveis de ambiente para segurança:

Defina as variáveis no arquivo .env:

TELEGRAM_BOT_TOKEN=<seu_token_telegram>

PINECONE_API_KEY=<sua_chave_api_pinecone>

OPENAI_API_KEY=<sua_chave_api_openai>

Passo 2: Configuração do Banco de Dados Vetorial

1. Configuração do Pinecone:

- Crie um índice no painel do Pinecone.
- Nomeie o índice, defina a dimensão para corresponder aos embeddings gerados (ex.: 1536 para GPT-3.5).
- Configure o tipo de índice para cosine ou dot product.

Inicialize o índice no código:

```
import pinecone

pinecone.init(api_key="YOUR_API_KEY", environment="us-west1-gcp")
index = pinecone.Index("nome_do_indice")
```

Passo 3: Desenvolvimento do Fluxo "Load Data into Database"

1. Receber Arquivo pelo Telegram:

- Use o webhook do Telegram para receber mensagens e arquivos enviados pelo usuário.

2. Processar o Arquivo PDF:

- Extraia o texto do PDF usando bibliotecas como PyPDF2 ou pdfplumber.

```
import pdfplumber

with pdfplumber.open("arquivo.pdf") as pdf:

    text = ""

    for page in pdf.pages:

        text += page.extract_text()
```

3. Dividir Texto em Chunks:

- Utilize uma ferramenta de splitting, como o CharacterTextSplitter da biblioteca LangChain.

```
from langchain.text_splitter import CharacterTextSplitter

splitter = CharacterTextSplitter(chunk_size=500, chunk_overlap=50)
chunks = splitter.split_text(text)
```

4. Gerar Embeddings:

- Use a API da OpenAI para gerar embeddings de cada chunk.

```
import openai

embeddings = [

    openai.Embedding.create(input=chunk,
engine="text-embedding-ada-002") ["data"][0]["embedding"]

    for chunk in chunks

]
```

5. Salvar no Pinecone:

- Envie os embeddings e IDs únicos para o índice.

```
for i, embedding in enumerate(embeddings):

    index.upsert(vectors=[(f"doc_{i}", embedding)])
```

Passo 4: Desenvolvimento do Fluxo "Chat with Database"

1. Receber Perguntas pelo Telegram:

- Configure o bot para escutar mensagens de texto enviadas pelos usuários.

2. Recuperar Dados do Pinecone:

- Use o índice do Pinecone para buscar os chunks mais relevantes.

```
query_embedding = openai.Embedding.create(
    input="pergunta_do_usuario", engine="text-embedding-ada-002"
) ["data"][0]["embedding"]

result = index.query(query_embedding, top_k=3, include_metadata=True)
```

3. Formular Resposta:

- Passe os textos recuperados para o modelo (GPT) gerar uma resposta final.

```
context = " ".join([match["metadata"]["text"] for match in
result["matches"]])
response = openai.Completion.create(
    engine="text-davinci-003", prompt=f"Com base no contexto:
{context}, responda: {user_query}", max_tokens=200
)
```

4. Enviar Resposta pelo Telegram:

- Use o método sendMessage da API Telegram para enviar a resposta ao usuário.

Passo 5: Testes e Validação

1. Teste o fluxo "Load Data into Database":
 - Envie um arquivo PDF pelo Telegram.
 - Verifique no painel do Pinecone se os vetores foram salvos corretamente.
2. Teste o fluxo "Chat with Database":
 - Envie perguntas relacionadas ao conteúdo do PDF.
 - Confirme se o bot responde com informações precisas e relevantes.

Passo 6: Documentação e Implantação

1. Documente todo o processo no README do repositório.
2. Implemente logs para monitorar erros e desempenho.
3. Faça o deploy em um servidor (como AWS ou Heroku) para manter o bot funcionando 24/7.